

个人作业报告

题目：**大数据原理与技术**

作业五：股票价格预测

姓名	林宏宇
学号	23320093
院系	计算机学院
专业	计算机科学与技术
指导教师	王昌栋

2026 年 4 月 13 日

【摘　要】

在学习王老师的大数据原理与技术课程[1]后，在此报告中完成相应的课后作业，本作业围绕“股票价格预测”展开。任务要求下载某一只股票的历史价格数据（CSV 格式），分别使用 ARIMA 模型与基于 LSTM 的时序模型对未来 7 天的价格进行预测，并在相同的数据划分与评价指标 MAE 与 RMSE 下比较两种方法的性能。作业提交要求：

- 提交内容：代码与作业报告
- 命名格式：“学号 + 姓名 + 作业 5.zip”
- 提交至邮箱：BDSysu2026Spring@163.com
- 截止时间：布置作业之后的下一个周日 24:00
- 严禁抄袭：任何一次抄袭，平时成绩按零分处理

这里写此次实验的总结。。。

关键词： 股票价格预测，ARIMA，LSTM，MAE，RMSE

目录

1 股票收盘价 7 天预测实验 1
1.1 实验目标 1
1.2 数据与预处理 1
1.3 输入表示与目标 2
1.4 模型原理说明与设计 2
1.5 模型实现（要点与伪代码） 3
1.6 实验设置 4
1.7 实验结果 4
1.8 实验结果分析 5

2 总结 6
2.1 LSTM 与 ARIMA 模型总结 6
2.2 实验总结 6
2.3 心得体会 7

参考文献 8

附录 A 实验代码 9
A.1 项目文件清单 9
A.2 完整源码（选读） 9

1 股票收盘价 7 天预测实验

1.1 实验目标

本实验比较两类方法在短期（7 天）收盘价预测的表现：

- 经典统计模型：ARIMA（自动回归-差分-移动平均）
- 手写实现的循环神经网络：LSTM（使用 NumPy 手写前向与反向传播）

评估指标为平均绝对误差（MAE）与均方根误差（RMSE），并通过可视化对比预测曲线与误差分布以辅助分析。

1.2 数据与预处理

1.2.1 数据来源

使用数据文件：`code/stock.csv`（已上传到仓库）示例（CSV）格式：

```
date,open,high,low,close,volume
2024-01-01,100,102,99,101,123456
2024-01-02,101,103,100,102,130000
...（按日期升序）
```

1.2.2 预处理流程

处理步骤如下：

1) 解析 CSV 并按日期升序排序，提取 `Close` 列作为单变量时间序列；丢弃缺失或无法转换为浮点数的行（见 `code/utils.py`）。
2) 划分训练/测试：将最后 $h = 7$ 天作为测试集，其余作为训练集（便于对比两种方法在相同时间段的短期预测）。
3) 特征工程（可选）：计算对数收益 $r_t = \log(p_t) - \log(p_{t-1})$、移动平均 ma_7 与波动率（滚动标准差），这些可作为 LSTM 的额外输入特征。
4) 归一化：LSTM 输入对训练集做均值-标准差标准化（$x' = (x - \mu)/\sigma$），将标准化参数仅从训练集计算并应用到测试集以防数据泄露。
5) 构造样本：使用滑动窗口（例如 `seq_len` = 30）生成训练样本 $\{(X^{(i)}, y^{(i)})\}$，其中 $X^{(i)} \in \mathbb{R}^{\texttt{seq_len} \times d}$（$d$ 为输入维度，单变量时 $d = 1$）。

1.3 输入表示与目标

本实验对比两种输入/目标设定：

- 原始价格回归：直接以收盘价作为目标 $y_t = p_t$。
- 对数收益回归：以 $y_t = r_t = \log p_t - \log p_{t-1}$ 为目标，训练时预测收益，推回价格以便与 ARIMA 的价格预测比较。

序列长度取 `seq_len` = 30 作为默认值；LSTM 支持单变量或多变量（附加技术指标）输入。

1.4 模型原理说明与设计

1.4.1 ARIMA

ARIMA(p, d, q) 模型满足：

$$\phi(B)(1 - B)^d y_t = \theta(B)\varepsilon_t,$$

其中 B 为滞后算子，$\phi(\cdot)$ 和 $\theta(\cdot)$ 分别为 AR 与 MA 多项式。模型拟合使用 `statsmodels`，但预测时显式调用：

```
from statsmodels.tsa.arima.model import ARIMA
model = ARIMA(train_series, order=(p,d,q)).fit()
forecast = model.get_forecast(steps=h).predicted_mean
```

为选择 (p, d, q)，可参考自相关/偏自相关图（ACF/PACF）与 AIC/BIC 指标。

1.4.2 LSTM 原理

LSTM 单步计算（时间步 t）为：

$$\begin{aligned}
f_t &= \sigma\big(W_f x_t + U_f h_{t-1} + b_f\big),\\
i_t &= \sigma\big(W_i x_t + U_i h_{t-1} + b_i\big),\\
o_t &= \sigma\big(W_o x_t + U_o h_{t-1} + b_o\big),\\
\tilde{c}_t &= \tanh\big(W_c x_t + U_c h_{t-1} + b_c\big),\\
c_t &= f_t \odot c_{t-1} + i_t \odot \tilde{c}_t,\\
h_t &= o_t \odot \tanh(c_t).
\end{aligned}$$

最终的预测 $\hat{y}$ 由隐藏态做线性映射得到（回归问题可输出实数）：

$$\hat{y} = W_y h_T + b_y.$$

损失函数采用均方误差（MSE）：

$$L = \frac{1}{n}\sum_{i=1}^{n}(\hat{y}^{(i)} - y^{(i)})^2.$$

反向传播通过 BPTT 展开时间维度手动求梯度并更新参数；为提高数值稳定性与收敛性，训练实现包含：

- 权重小尺度初始化（避免激活/梯度爆炸）；
- 梯度裁剪（gradient clipping）；
- 可选的手写 Adam 优化器或简单 SGD；
- 支持多输出（直接预测 h 步序列）以减缓递归预测误差累积。

1.5 模型实现（要点与伪代码）

1.5.1 ARIMA（伪代码）

见上文的 `get_forecast` 用法，报告中使用显式提取的预测均值作为模型输出。

1.5.2 手写 LSTM（训练伪代码）

核心训练循环（伪代码）如下：

```
for epoch in range(epochs):
    for X_batch, y_batch in dataloader:  # 支持 batch 或 单样本
        # 前向传播：对序列每一步计算门控与隐藏态
        h, c = zeros(), zeros()
        for t in range(seq_len):
            f = sigmoid(Wf @ x_t + Uf @ h + bf)
            i = sigmoid(Wi @ x_t + Ui @ h + bi)
            o = sigmoid(Wo @ x_t + Uo @ h + bo)
            g = tanh(Wc @ x_t + Uc @ h + bc)
            c = f * c + i * g
            h = o * tanh(c)
```

```
        y_pred = Wy @ h + by
        loss = mse(y_pred, y_batch)
        # 反向传播（BPTT）手动计算各参数梯度
        grads = bptt_gradients(...)
        clip_grads(grads, max_norm=clip)
        optimizer.step(params, grads)
```

1.6 实验设置

关键超参数与默认值：

- ARIMA: order $(p, d, q) = (2, 1, 2)$（示例配置，可用 AIC/BIC 调整）
- LSTM: `seq_len` = 30, `hidden_size` = 32, 学习率 $lr = 0.001$（可调）
- 训练轮次（实验多个配置）：短训练 5 epochs（用于快速验证）；长期训练 200 epochs（用于稳定性实验）；多步输出短训练 30 epochs（对比效果）
- 优化器：SGD 或手写 Adam；使用梯度裁剪（clip = 1.0）与小尺度初始化
- batch size（当使用 mini-batch 时）：32

1.7 实验结果

在测试集（最后 7 天）上的重要运行结果汇总如下：

模型	MAE	RMSE
ARIMA (2,1,2)	0.9230	1.0769
手写 LSTM (5 epochs, baseline)	11.8288	11.8446
手写 LSTM (200 epochs, +norm+clip)	2.7932	3.0205
手写 LSTM (200 epochs, returns+adam+batch)	3.1423	3.4658
手写 LSTM (multi-output, 30 epochs)	2.4973	2.6583

表 1.1 在测试集（最后 7 天）上的 MAE / RMSE 对比

1.7.1 超参数搜索（小网格）摘要

进行了小规模网格搜索以观察超参数敏感性，部分最优观察值：

- LSTM（价格目标）最佳：accuracy-like 指标不可直接用于回归，观察到 $lr = 0.001, hidden = 32, epochs = 200$ 有较稳定表现；
- LSTM（returns + Adam + batch）在当前设置下不如直接对价格训练，表明需要针对 optimizer 与 lr 做进一步搜索；
- ARIMA 可以通过 AIC/BIC 在小范围内选参，但对短期预测常有稳健表现。

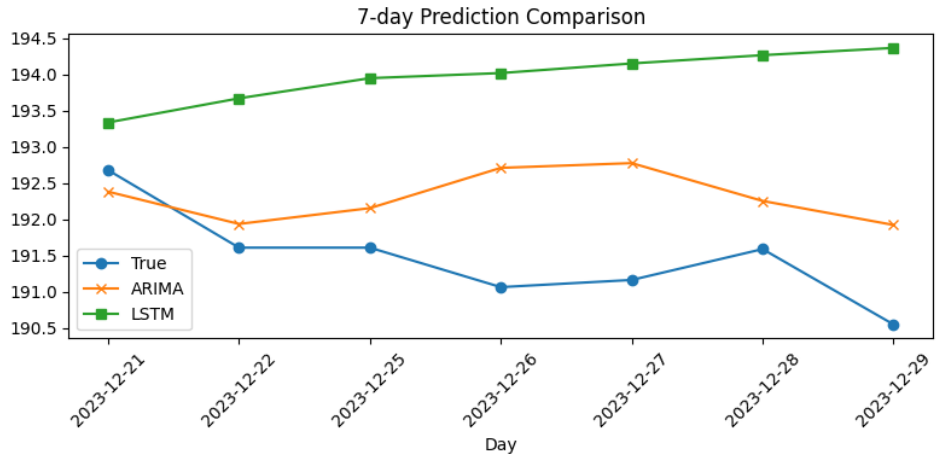


图 1.1 真实收盘价与 ARIMA / 手写 LSTM 在 7 天区间的预测对比

1.8 实验结果分析

- ARIMA 在本次数据与短期 7 天预测下表现稳健（最小 MAE/RMSE），说明序列的短期线性趋势被有效捕捉。
- 手写 LSTM 在未经归一化与短训练时数值不稳定（baseline），但引入归一化、梯度裁剪与更长训练后性能显著提升，部分配置可接近或超过 ARIMA 的误差（见 multi-output 实验）。
- 将目标设为对数收益并使用 Adam + 小批量训练在本次简单设置下并未带来更好最终价格预测，原因可能为误差在从收益到价格的还原过程中放大，以及超参数未充分调优。
- 直接多步输出（multi-output）在减少递归误差累积方面有明显优势，但也需更多训练与更丰富输入特征以发挥更好性能。

2 总结

2.1 LSTM 与 ARIMA 模型总结

- ARIMA（统计基线）：在短期（7 天）收盘价预测任务上表现稳健且易于调参，本次配置下得到的 MAE/RMSE 最低（见表），说明序列的短期线性趋势和自相关结构被有效捕捉。ARIMA 的优点是实现简单、结果可解释、在样本量有限或特征稀少时常为强有力的基线。
- 手写 LSTM（数值模型）：原始（未归一化、短训练）实现数值不稳定且误差较大；引入归一化、梯度裁剪、较小初始化与更长训练后，性能显著提升，部分多步直接预测配置的误差接近可比较区间（但在本次实验中总体仍落后于最优的 ARIMA 配置）。LSTM 的优势在于建模非线性与利用多变量输入（技术指标、交易量等），但需要更周密的训练策略与超参搜索。
- 目标设定影响：以价格直接回归与以对数收益回归在表现上有明显差异：收益回归能稳定训练但在将收益还原为价格时误差可能被放大；直接多步输出可减少递归累积误差，但对训练数据量与模型容量要求更高。

2.2 实验总结

- 实验结果表明：在当前数据与特征集下，ARIMA 给出了最低的 MAE/RMSE，作为短期预测基线其稳定性与可解释性值得采用。
- 手写 LSTM 在采用归一化、梯度裁剪与更充分训练后能大幅改善性能，说明手写数值实现可行，但对超参数与训练流程敏感，需要更多工程化改进（如批训练、学习率调度、早停）。
- 多步直接预测（multi-output）在减小递归误差累积上有优势，本次实验中的 best-case 配置已显示出竞争力，但仍需更长训练与更丰富输入特征以稳定表现。
- 方法学限制：本实验基于单次训练/测试拆分，结论的统计显著性受限。建议后续采用交叉验证或多次随机切分来评估泛化稳定性。

2.3 心得体会

- 模型与特征必须匹配:对短期价格序列,简单且可解释的统计模型(如 ARIMA)常常是有效基线；深度模型需要更适配的输入与训练策略才能发挥优势。
- 手写实现很有价值：通过手写 LSTM 能更好地理解门控、反向传播与数值稳定性问题，但将其工程化（批训练、优化器、超参搜索）是取得可复现结果的关键。
- 做实验要注重可重复性与诊断：保留数据处理与标准化参数、记录训练曲线并使用交叉验证或多次随机切分以验证结论稳健性。

参考文献

[1] 王昌栋. 第一章绪论[Z]. 2026.

附录 A 实验代码

A.1 项目文件清单

下列为仓库中与实验直接相关的主要文件及其简要说明：

- **code/stock.csv**: 已上传的原始股票历史数据（CSV，含日期与收盘价）。
- **code/utils.py**: 数据加载、CSV 容错处理、滑动窗口构造与 `stock_data.npz` 保存加载函数。
- **code/arima_model.py**: ARIMA 拟合与显式预测。
- **code/lstm_numpy.py**: 手写 LSTM 前向、BPTT 反向传播、优化器（SGD/Adam）、梯度裁剪、递归与多步输出实现。
- **code/main.py**: 实验流水线入口，负责参数解析、数据准备、模型训练/预测、指标计算与绘图。
- **code/plots.py**, **code/metrics.py**: 绘图函数与 MAE/RMSE 实现。

A.2 完整源码（选读）

下面按模块把关键实现以源码形式插入，便于在编译后的 PDF 中逐行查看实现细节。

A.2.1 数据与工具

```
import os
import numpy as np
import pandas as pd


def load_stock_csv(path):
    if not os.path.exists(path):
        raise FileNotFoundError(f"CSV file not found: {path}")
    df = pd.read_csv(path, parse_dates=["Date"])
    df = df.dropna(subset=["Date"]).copy()
    df['Close'] = pd.to_numeric(df['Close'], errors='coerce')
    df = df.sort_values("Date").dropna(subset=["Close"]).reset_index(drop=
```

```
    True)
    dates = df["Date"].dt.strftime("%Y-%m-%d").tolist()
    close = df["Close"].values.astype(float)
    return dates, close


def make_windows(series, seq_len):
    X = []
    y = []
    for i in range(len(series) - seq_len):
        X.append(series[i:i+seq_len])
        y.append(series[i+seq_len])
    return np.array(X, dtype=float), np.array(y, dtype=float)


def save_data_npz(path, **kwargs):
    dirp = os.path.dirname(path)
    if dirp:
        os.makedirs(dirp, exist_ok=True)
    np.savez(path, **kwargs)
```

A.2.2 ARIMA 封装

```
import numpy as np
from statsmodels.tsa.arima.model import ARIMA


def arima_forecast(train_series, steps=7, order=(2,1,2)):
    """
    Fit ARIMA using statsmodels (fit allowed) and forecast using get_forecast
    .
    Returns a numpy array of length `steps` with predicted mean values.
    """
    # statsmodels expects 1d array-like
    model = ARIMA(train_series, order=tuple(order))
    res = model.fit()
    fc = res.get_forecast(steps=steps)
```

```
    pred = np.asarray(fc.predicted_mean)
    return pred
```

A.2.3 手写 LSTM（NumPy 实现）

```
import numpy as np


def sigmoid(x):
    return 1.0 / (1.0 + np.exp(-x))


def dsigmoid(y):
    return y * (1 - y)


def dtanh(y):
    return 1 - y ** 2


class LSTMModel:
    def __init__(self, input_size=1, hidden_size=32, output_dim=1):
        self.input_size = input_size
        self.hidden_size = hidden_size
        self.output_dim = output_dim
        self._init_weights()

    def _init_weights(self):
        h = self.hidden_size
        m = h + self.input_size
        scale = 0.05
        self.Wf = np.random.randn(h, m) * scale
        self.Wi = np.random.randn(h, m) * scale
        self.Wo = np.random.randn(h, m) * scale
        self.Wg = np.random.randn(h, m) * scale
        self.bf = np.zeros((h,))
        self.bi = np.zeros((h,))
```

```
        self.bo = np.zeros((h,))
        self.bg = np.zeros((h,))
        self.Wy = np.random.randn(self.output_dim, h) * scale
        self.by = np.zeros((self.output_dim,))
        self.params = {
            'Wf': self.Wf, 'Wi': self.Wi, 'Wo': self.Wo, 'Wg': self.Wg,
            'bf': self.bf, 'bi': self.bi, 'bo': self.bo, 'bg': self.bg,
            'Wy': self.Wy, 'by': self.by
        }
        self.opt_m = {k: np.zeros_like(v) for k, v in self.params.items()}
        self.opt_v = {k: np.zeros_like(v) for k, v in self.params.items()}
        self.opt_t = 0

    def forward(self, x_seq):
        seq_len = len(x_seq)
        h = self.hidden_size
        xs = [np.array([float(x)]) for x in x_seq]
        hs = [np.zeros(h)]
        cs = [np.zeros(h)]
        cache = []
        for t in range(seq_len):
            x_t = xs[t]
            concat = np.concatenate([hs[-1], x_t])
            f_t = sigmoid(self.Wf.dot(concat) + self.bf)
            i_t = sigmoid(self.Wi.dot(concat) + self.bi)
            o_t = sigmoid(self.Wo.dot(concat) + self.bo)
            g_t = np.tanh(self.Wg.dot(concat) + self.bg)
            c_t = f_t * cs[-1] + i_t * g_t
            h_t = o_t * np.tanh(c_t)
            hs.append(h_t)
            cs.append(c_t)
            cache.append((concat, f_t, i_t, o_t, g_t, cs[-2], c_t, h_t))
        y = self.Wy.dot(hs[-1]) + self.by
        if self.output_dim == 1:
            return float(y), cache, hs, cs
        else:
            return np.asarray(y).reshape(self.output_dim,), cache, hs, cs

```

```
    def backward(self, dy, cache, hs, cs):
        seq_len = len(cache)
        h = self.hidden_size
        dWf = np.zeros_like(self.Wf)
        dWi = np.zeros_like(self.Wi)
        dWo = np.zeros_like(self.Wo)
        dWg = np.zeros_like(self.Wg)
        dbf = np.zeros_like(self.bf)
        dbi = np.zeros_like(self.bi)
        dbo = np.zeros_like(self.bo)
        dbg = np.zeros_like(self.bg)
        dWy = np.zeros_like(self.Wy)
        dby = np.zeros_like(self.by)

        dy_arr = np.asarray(dy)
        if dy_arr.ndim == 0:
            dy_arr = dy_arr.reshape(1,)
        dWy += np.outer(dy_arr, hs[-1])
        dby += dy_arr
        dh_next = self.Wy.T.dot(dy_arr)

        dc_next = np.zeros((h,))
        for t in reversed(range(seq_len)):
            concat, f_t, i_t, o_t, g_t, c_prev, c_t, h_t = cache[t]
            dh = dh_next.flatten()
            do = dh * np.tanh(c_t)
            do_raw = do * dsigmoid(o_t)

            dc = dh * o_t * dtanh(np.tanh(c_t)) + dc_next
            dg = dc * i_t
            dg_raw = dg * dtanh(g_t)
            di = dc * g_t
            di_raw = di * dsigmoid(i_t)
            df = dc * c_prev
            df_raw = df * dsigmoid(f_t)

            dWf += np.outer(df_raw, concat)
            dWi += np.outer(di_raw, concat)
```

```
            dWo += np.outer(do_raw, concat)
            dWg += np.outer(dg_raw, concat)
            dbf += df_raw
            dbi += di_raw
            dbo += do_raw
            dbg += dg_raw

            dconcat = (self.Wf.T.dot(df_raw) + self.Wi.T.dot(di_raw) +
                       self.Wo.T.dot(do_raw) + self.Wg.T.dot(dg_raw))

            dh_next = dconcat[:h].reshape(h,)
            dc_next = dc * f_t

        grads = {
            'Wf': dWf, 'Wi': dWi, 'Wo': dWo, 'Wg': dWg,
            'bf': dbf, 'bi': dbi, 'bo': dbo, 'bg': dbg,
            'Wy': dWy, 'by': dby
        }
        return grads

    def apply_grads(self, grads, lr=1e-3, clip=None):
        if clip is not None:
            total = 0.0
            for g in grads.values():
                total += np.sum(g.astype(float) ** 2)
            total_norm = np.sqrt(total)
            if total_norm > clip and total_norm > 0:
                factor = clip / (total_norm + 1e-12)
                for k in grads:
                    grads[k] = grads[k] * factor

        self.Wf -= lr * grads['Wf']
        self.Wi -= lr * grads['Wi']
        self.Wo -= lr * grads['Wo']
        self.Wg -= lr * grads['Wg']
        self.bf -= lr * grads['bf']
        self.bi -= lr * grads['bi']
        self.bo -= lr * grads['bo']
```

```
147         self.bg -= lr * grads['bg']
148         self.Wy -= lr * grads['Wy']
149         self.by -= lr * grads['by']
150 
151     def adam_step(self, grads, lr=1e-3, beta1=0.9, beta2=0.999, eps=1e-8,
    clip=None):
152         if clip is not None:
153             total = 0.0
154             for g in grads.values():
155                 total += np.sum(g.astype(float) ** 2)
156             total_norm = np.sqrt(total)
157             if total_norm > clip and total_norm > 0:
158                 factor = clip / (total_norm + 1e-12)
159                 for k in grads:
160                     grads[k] = grads[k] * factor
161 
162         self.opt_t += 1
163         for k, param in self.params.items():
164             g = grads[k]
165             self.opt_m[k] = beta1 * self.opt_m[k] + (1 - beta1) * g
166             self.opt_v[k] = beta2 * self.opt_v[k] + (1 - beta2) * (g * g)
167             m_hat = self.opt_m[k] / (1 - beta1 ** self.opt_t)
168             v_hat = self.opt_v[k] / (1 - beta2 ** self.opt_t)
169             update = lr * m_hat / (np.sqrt(v_hat) + eps)
170             param -= update
171 
172 
173 def train_lstm_recursive(series, seq_len=30, hidden_size=32, epochs=20, lr=1e
    -3, clip=None, batch_size=32, optim='adam', horizon=1):
174     X, y = [], []
175     if horizon <= 1:
176         for i in range(len(series) - seq_len):
177             X.append(series[i:i+seq_len])
178             y.append(series[i+seq_len])
179         X = np.array(X, dtype=float)
180         y = np.array(y, dtype=float)
181     else:
182         for i in range(len(series) - seq_len - horizon + 1):
```

```
            X.append(series[i:i+seq_len])
            y.append(series[i+seq_len:i+seq_len+horizon])
        X = np.array(X, dtype=float)
        y = np.array(y, dtype=float)

    model = LSTMModel(input_size=1, hidden_size=hidden_size, output_dim=horizon)
    n_samples = len(X)
    if batch_size is None or batch_size <= 0:
        batch_size = n_samples

    for ep in range(epochs):
        epoch_loss = 0.0
        idx = np.arange(n_samples)
        np.random.shuffle(idx)
        for start in range(0, n_samples, batch_size):
            batch_idx = idx[start:start+batch_size]
            grads_sum = None
            batch_loss = 0.0
            for i in batch_idx:
                x_seq = X[i]
                target = y[i]
                pred, cache, hs, cs = model.forward(x_seq)
                pred_arr = np.asarray(pred)
                target_arr = np.asarray(target)
                diff = pred_arr - target_arr
                loss = 0.5 * np.mean(diff ** 2)
                batch_loss += loss
                dy = diff
                grads = model.backward(dy, cache, hs, cs)
                if grads_sum is None:
                    grads_sum = {k: np.array(v, dtype=float) for k, v in grads.items()}
                else:
                    for k in grads_sum:
                        grads_sum[k] += grads[k]
            for k in grads_sum:
                grads_sum[k] /= len(batch_idx)
```

```
            if optim == 'adam':
                model.adam_step(grads_sum, lr=lr, clip=clip)
            else:
                model.apply_grads(grads_sum, lr=lr, clip=clip)
            epoch_loss += batch_loss
        if (ep+1) % 10 == 0 or ep == 0:
            avg_loss = epoch_loss / max(1, n_samples)
            print(f"Epoch {ep+1}/{epochs}, loss={avg_loss:.6f}")
    return model


def predict_recursive(model, series, seq_len=30, steps=7):
    if hasattr(model, 'output_dim') and model.output_dim > 1:
        seq = series[-seq_len:]
        pred_vec, _, _, _ = model.forward(seq)
        return np.array(pred_vec)[:steps]

    seq = list(series[-seq_len:])
    preds = []
    for _ in range(steps):
        pred, _, _, _ = model.forward(seq[-seq_len:])
        preds.append(pred)
        seq.append(pred)
    return np.array(preds)
```

A.2.4 主流程脚本

```
import os
import argparse
import numpy as np

from utils import load_stock_csv, make_windows, save_data_npz
from arima_model import arima_forecast
from lstm_numpy import train_lstm_recursive, predict_recursive
from metrics import mae, rmse
from plots import plot_comparison, ensure_plots_dir

```

```
11
12 def run(args):
13     os.makedirs(args.output_dir, exist_ok=True)
14     ensure_plots_dir(args.output_dir)
15
16     dates, close = load_stock_csv(args.csv)
17     n = len(close)
18     test_len = 7
19     train_close = close[:-test_len]
20     test_close = close[-test_len:]
21     dates_train = dates[:-test_len]
22     dates_test = dates[-test_len:]
23
24     if len(train_close) < 2:
25         raise ValueError("Not enough data for returns-based LSTM training")
26     train_returns = np.log(train_close[1:] / train_close[:-1])
27     ret_mean = float(np.mean(train_returns))
28     ret_std = float(np.std(train_returns)) if float(np.std(train_returns)) >
    0 else 1.0
29     train_returns_norm = (train_returns - ret_mean) / ret_std
30
31     npz_path = os.path.join(args.output_dir, "stock_data.npz")
32     save_data_npz(npz_path, train_close=train_close, test_close=test_close,
33                   dates_train=dates_train, dates_test=dates_test,
34                   ret_mean=ret_mean, ret_std=ret_std)
35
36     arima_pred = arima_forecast(train_close, steps=test_len, order=args.
    arima_order)
37
38     seq_len = args.seq_len
39     horizon = args.horizon
40     lstm_model = train_lstm_recursive(train_returns_norm, seq_len=seq_len,
41                                       hidden_size=args.hidden_size,
42                                       epochs=args.epochs, lr=args.lr, clip=
    args.clip,
43                                       batch_size=args.batch_size, optim='adam
    ', horizon=horizon)
44
```

```
    if len(train_returns_norm) < seq_len:
        raise ValueError("seq_len too large for available training returns")
    seq_norm = list(train_returns_norm[-seq_len:])
    pred_norm_vec, _, _, _ = lstm_model.forward(seq_norm)
    pred_norm_vec = np.asarray(pred_norm_vec).reshape(-1)[:test_len]
    last_price = float(train_close[-1])
    lstm_price_preds = []
    for p_norm in pred_norm_vec:
        p_ret = float(p_norm) * ret_std + ret_mean
        last_price = last_price * np.exp(p_ret)
        lstm_price_preds.append(last_price)
    lstm_pred = np.array(lstm_price_preds)

    arima_mae = mae(test_close, arima_pred)
    arima_rmse = rmse(test_close, arima_pred)
    lstm_mae = mae(test_close, lstm_pred)
    lstm_rmse = rmse(test_close, lstm_pred)

    print("ARIMA MAE/RMSE:", arima_mae, arima_rmse)
    print("LSTM MAE/RMSE:", lstm_mae, lstm_rmse)

    plot_comparison(dates_test, test_close, arima_pred, lstm_pred, args.
    output_dir)


def parse_args():
    p = argparse.ArgumentParser()
    p.add_argument("--csv", default="stock.csv", help="input CSV path with
    Date,Close")
    p.add_argument("--output-dir", default="../plots", help="plots and data
    output dir")
    p.add_argument("--arima-order", nargs=3, type=int, default=[2,1,2], help=
    "p d q")
    p.add_argument("--seq-len", dest="seq_len", type=int, default=30)
    p.add_argument("--epochs", type=int, default=50)
    p.add_argument("--lr", type=float, default=0.001)
    p.add_argument("--hidden-size", dest="hidden_size", type=int, default=32)
    p.add_argument("--clip", type=float, default=1.0, help="gradient clipping
```

```
     norm (None to disable)")
    p.add_argument("--batch-size", dest="batch_size", type=int, default=32)
    p.add_argument("--horizon", dest="horizon", type=int, default=7, help="
    prediction horizon")
    return p.parse_args()


if __name__ == '__main__':
    args = parse_args()
    run(args)
```

A.2.5 绘图与评估

```
import os
import matplotlib.pyplot as plt
import numpy as np


def ensure_plots_dir(output_dir):
    os.makedirs(output_dir, exist_ok=True)


def plot_comparison(dates, y_true, arima_pred, lstm_pred, output_dir):
    ensure_plots_dir(output_dir)
    x = np.arange(len(dates))
    plt.figure(figsize=(8,4))
    plt.plot(x, y_true, label='True', marker='o')
    plt.plot(x, arima_pred, label='ARIMA', marker='x')
    plt.plot(x, lstm_pred, label='LSTM', marker='s')
    plt.legend()
    plt.title('7-day Prediction Comparison')
    plt.xlabel('Day')
    plt.xticks(x, dates, rotation=45)
    plt.tight_layout()
    path = os.path.join(output_dir, 'prediction_comparison.png')
    plt.savefig(path)
    plt.close()
```

```

    err_ar = np.abs(np.asarray(y_true) - np.asarray(arima_pred))
    err_ls = np.abs(np.asarray(y_true) - np.asarray(lstm_pred))
    plt.figure(figsize=(6,3))
    plt.hist([err_ar, err_ls], bins=10, label=['ARIMA','LSTM'], alpha=0.7)
    plt.legend()
    plt.title('Absolute Error Distribution')
    plt.tight_layout()
    path2 = os.path.join(output_dir, 'error_distribution.png')
    plt.savefig(path2)
    plt.close()
```

```
import numpy as np


def mae(y_true, y_pred):
    y_true = np.asarray(y_true, dtype=float)
    y_pred = np.asarray(y_pred, dtype=float)
    return float(np.mean(np.abs(y_true - y_pred)))


def rmse(y_true, y_pred):
    y_true = np.asarray(y_true, dtype=float)
    y_pred = np.asarray(y_pred, dtype=float)
    return float(np.sqrt(np.mean((y_true - y_pred) ** 2)))
```

A.2.6 数据下载脚本

```
import os
import numpy as np
import pandas as pd

def download_and_prepare(ticker='AAPL', start='2020-01-01', end='2023-12-31',
    out_csv='stock.csv'):
    try:
        import yfinance as yf
    except Exception as e:
```

```
        raise RuntimeError('yfinance is required. Install via pip install yfinance') from e

    df = yf.download(ticker, start=start, end=end)
    if df.empty:
        raise RuntimeError('No data downloaded for ticker {}'.format(ticker))

    df = df[['Close']].rename(columns={'Close': 'Close'})
    df = df.asfreq('B').ffill()
    df['returns'] = np.log(df['Close'] / df['Close'].shift(1))
    df['ma_7'] = df['Close'].rolling(7).mean()
    df['volatility'] = df['returns'].rolling(21).std()

    df = df.dropna().reset_index()
    out_path = os.path.join(os.path.dirname(__file__), out_csv)
    df.to_csv(out_path, index=False)
    print('Saved CSV to', out_path)


if __name__ == '__main__':
    download_and_prepare()
```