中山大學 SUN YAT-SEN UNIVERSITY
国家超级计算广州中心 NATIONAL SUPERCOMPUTER CENTER IN GUANGZHOU

并行程序设计与算法（实验）

9-CUDA矩阵转置

吴迪、刘学正

实验概要

实验内容

- 基于CUDA的Hello World 并行输出
- 使用 CUDA 实现矩阵转置及优化

实验目的

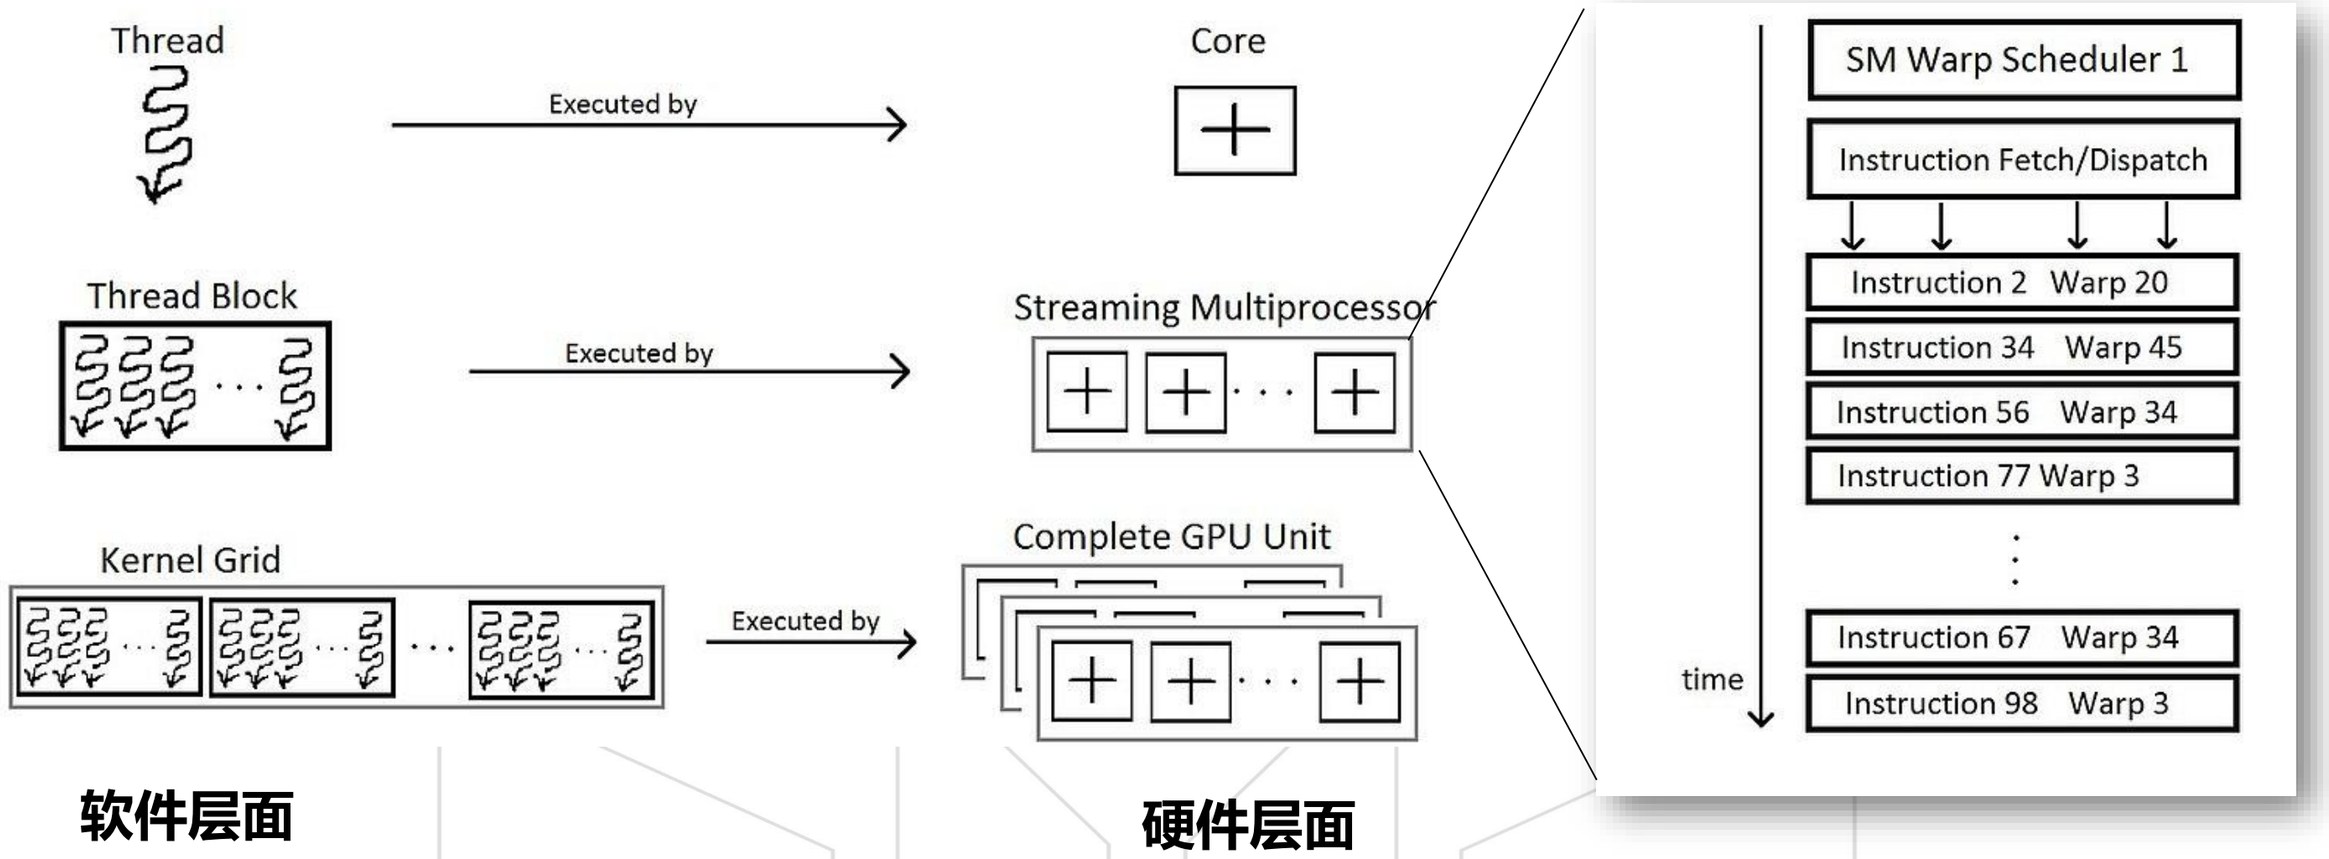
- 熟悉 CUDA 线程层次结构（grid、block、thread）和观察warp调度行为
- 掌握 CUDA 内存优化技术（共享内存、合并访问）
- 理解线程块配置对性能的影响

实验内容 1

- **CUDA Hello World**
  - 创建n个线程块，每个线程块的维度为m×k
  - 每个线程均输出线程块编号、二维块内线程编号
    - 如， “Hello World from Thread (1, 2) in Block 10!”
    - 主线程输出“Hello World from the host!”
    - main 函数结束前，调用cudaDeviceSynchronize()
  - 要求：完成上述内容，观察输出，并回答线程输出顺序是否有规律?

CUDA执行模型

- 从逻辑组织到硬件调度



实验内容 2

- **CUDA 矩阵转置**
  - 使用CUDA完成并行矩阵转置
  - 随机生成$n \times n$的矩阵A
  - 对其进行转置得到A^T
  - 分析不同线程块大小、矩阵规模、访存方式（全局内存访问，共享内存访问）、任务/数据划分和映射方式，对程序性能的影响

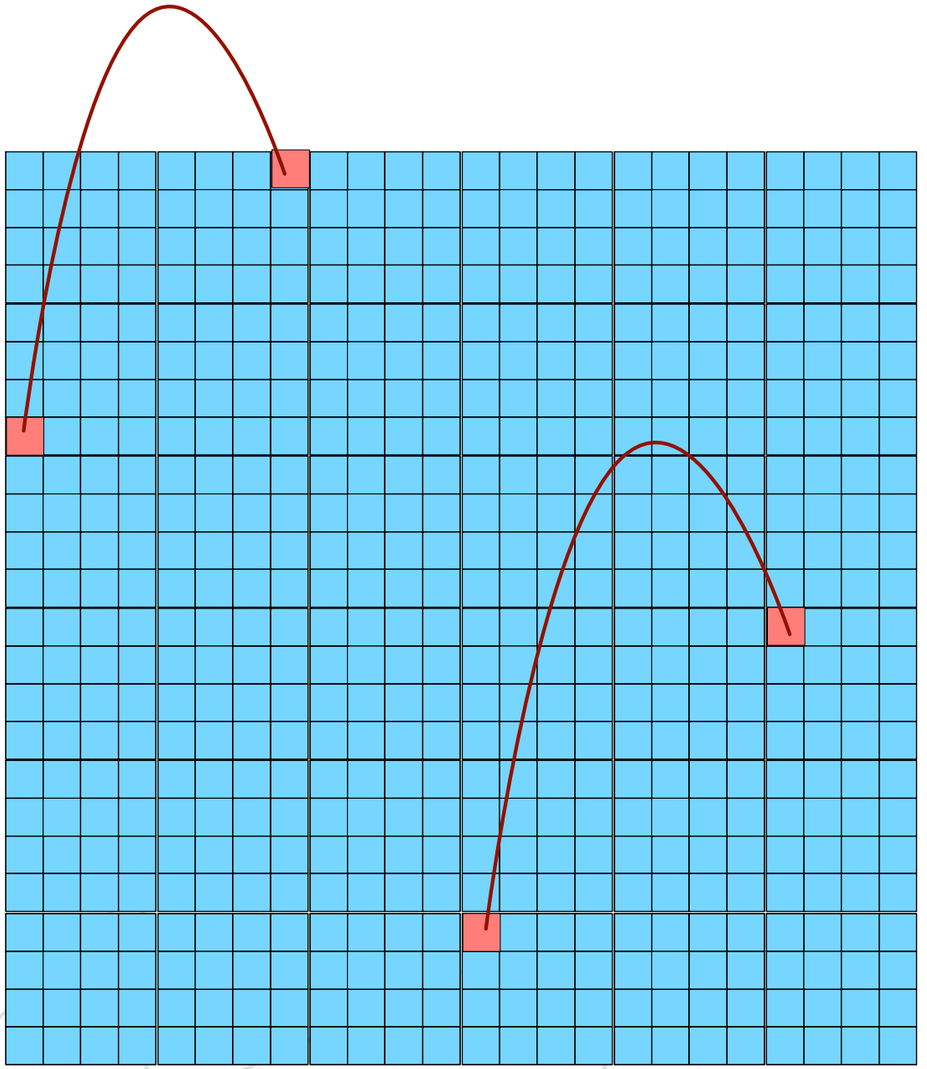
矩阵转置

- 全局内存的CUDA矩阵转置
  - 交换行和列索引
  - 简单但不高效

```
__global__ void transpose(int* out, int* in, int n){

    int bx = blockIdx.x*blockDim.x;
    int by = blockIdx.y*blockDim.y;
    int tx = threadIdx.x;
    int ty = threadIdx.y;

    out[(bx+tx)*n+by+ty]=in[(by+ty)*n+bx+tx];
}
```



Q：为什么仅使用全局内存效率不高？

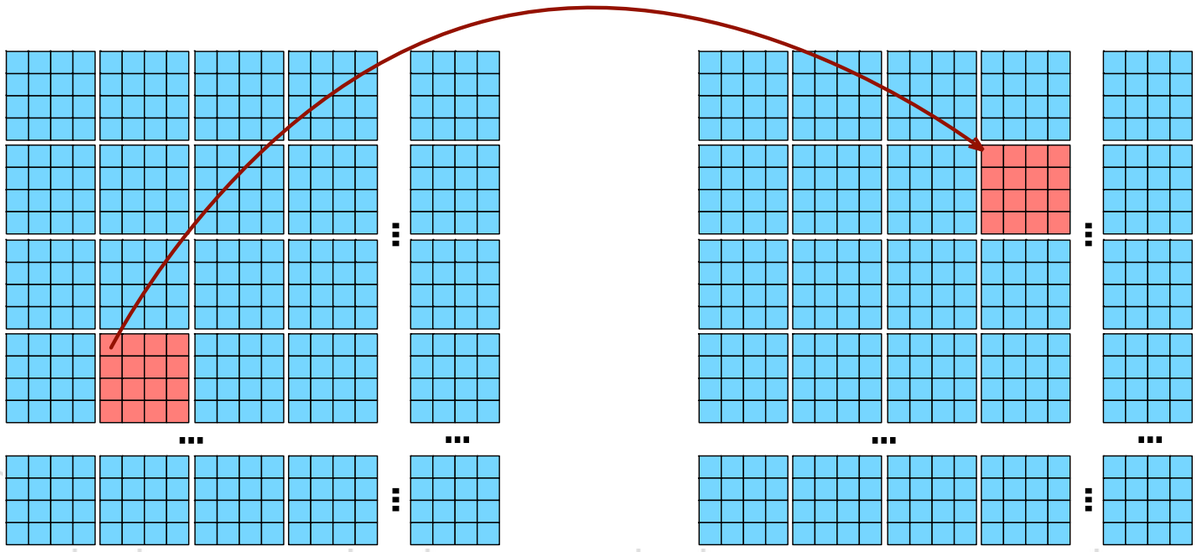
A：非合并写入导致带宽利用率低、缓存命中率低

矩阵转置

- **使用共享内存的CUDA矩阵转置**
  - 将矩阵划分为数据块
  - 从全局内存Global Memory中读入第（i，j）个数据块至共享内存
  - 每个线程块处理一个数据块的转置：元素 (i, j) → (j, i)
  - 从共享内存Shared Memory中写出至第（j，i）个数据块

Q: 为什么使用共享内存效率更高?

A：利用更快的共享内存提升转置效率，同时实现合并写入全局内存



矩阵转置

使用共享内存的CUDA矩阵转置

```
__global__ void transpose(int* out, int* in, int n, int m){
    __shared__ int smem[BDIM*BDIM];

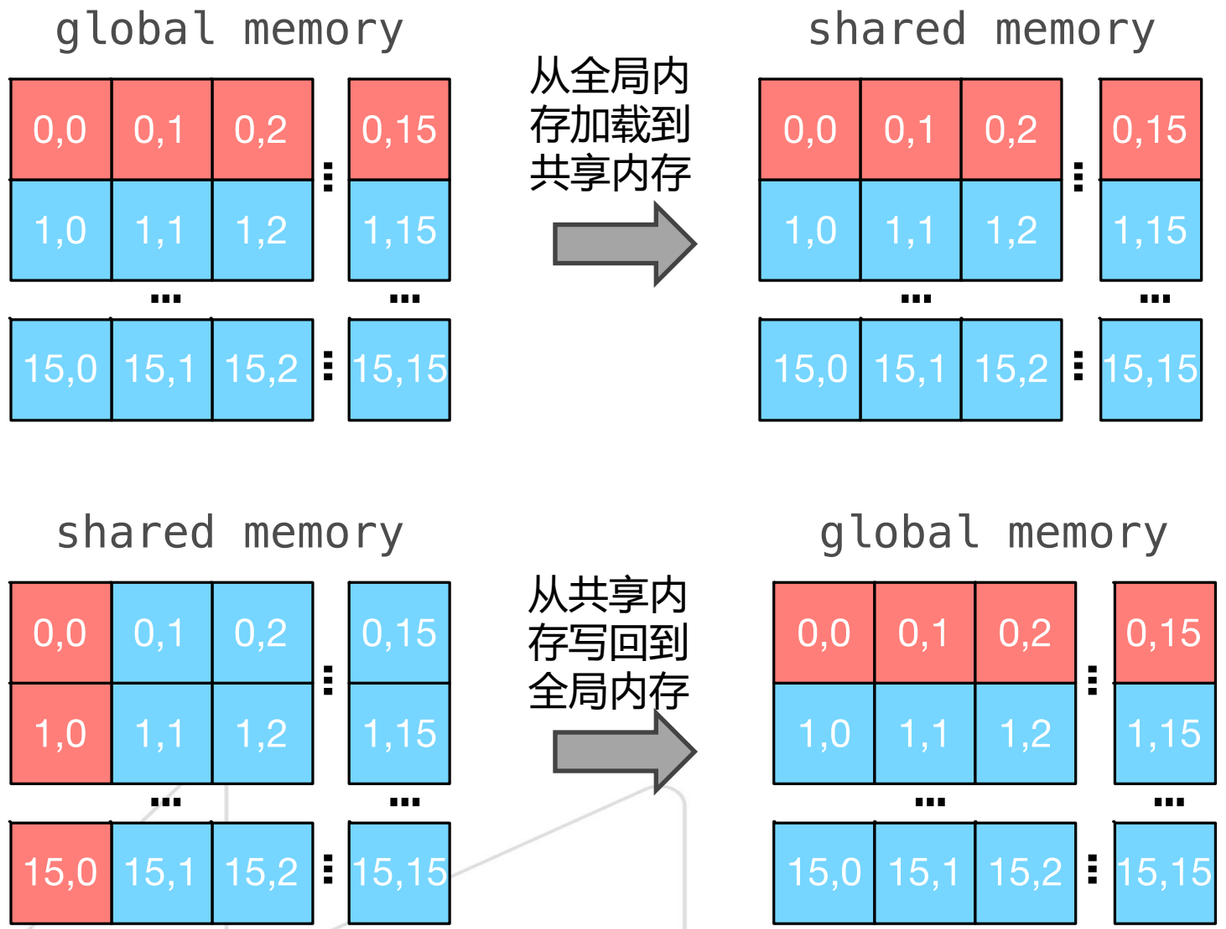
    int bx = blockIdx.x*blockDim.x;
    int by = blockIdx.y*blockDim.y;
    int tx = threadIdx.x;
    int ty = threadIdx.y;

    smem[ty*BDIM+tx] = in[(by+ty)*m+bx+tx];
    __syncthreads();

    out[(bx+ty)*n+by+tx]=smem[tx*BDIM+ty];
}
```

out[(bx+tx)*n+by+ty]=smem[ty*BDIM+tx];

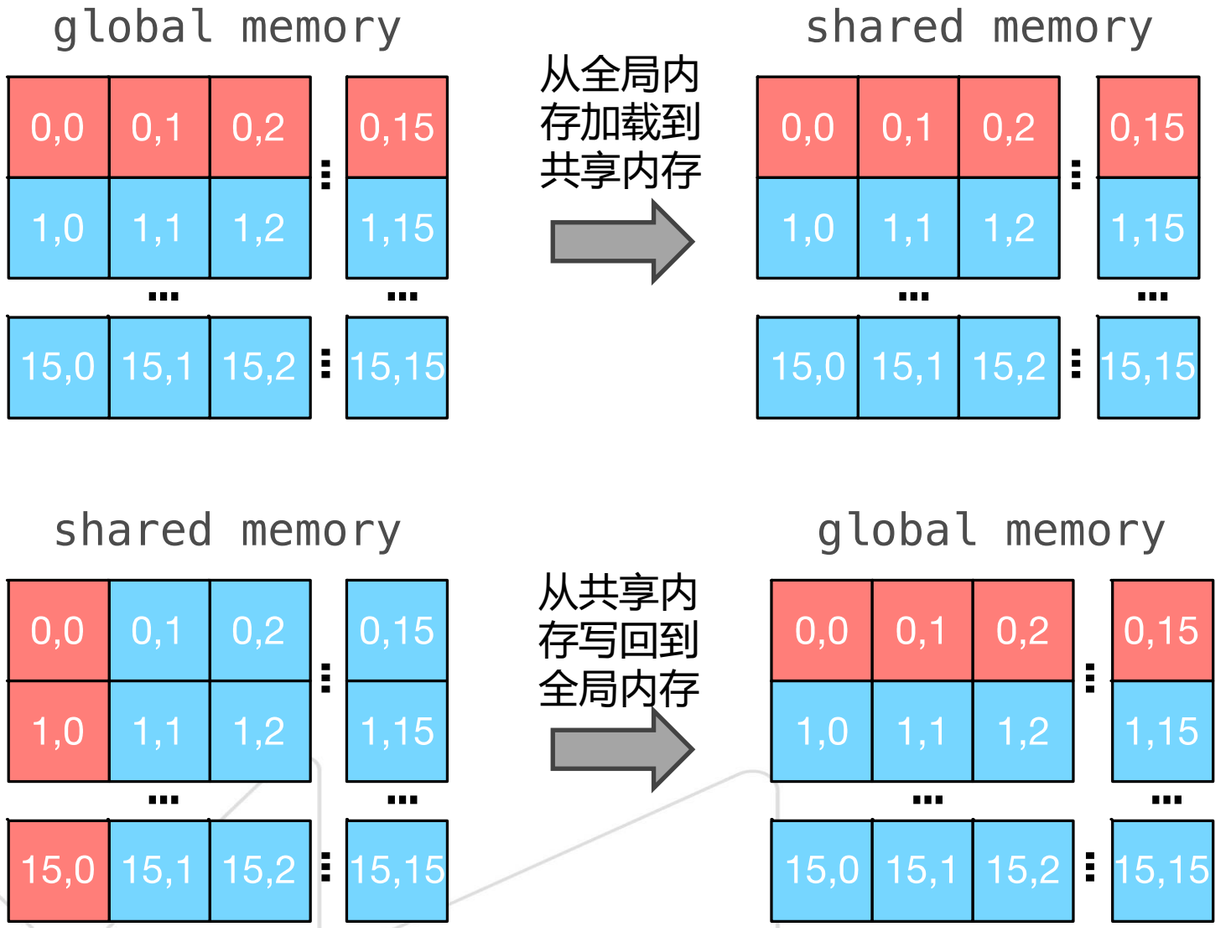
能不能改写？



矩阵转置

使用共享内存的CUDA矩阵转置

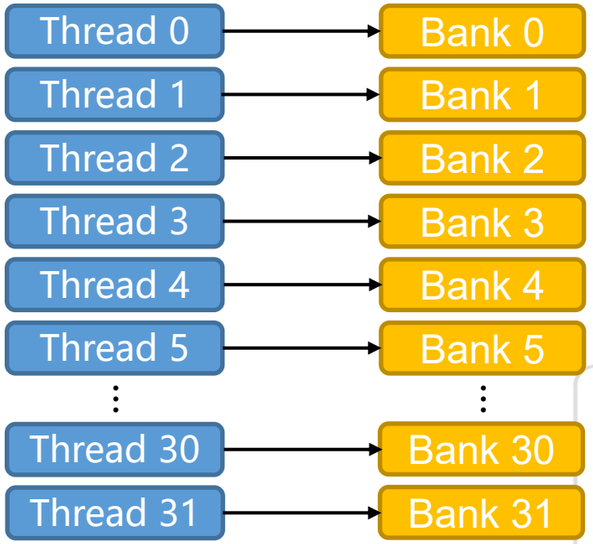
- 全局内存访问模式
  - 读写全局内存均为合并存储
  - 线程块宽度为16倍数
- 共享内存访问模式
  - 不受合并存储约束
  - 存在存储体冲突

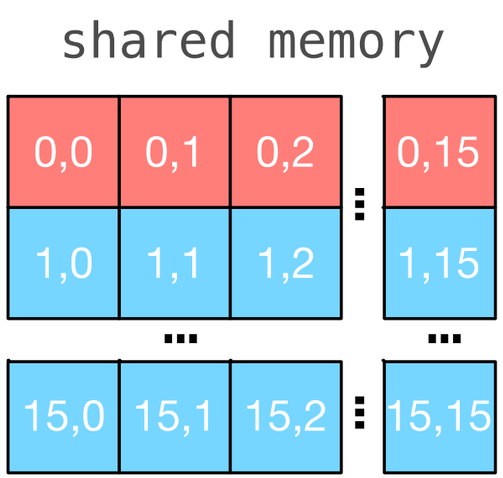


矩阵转置

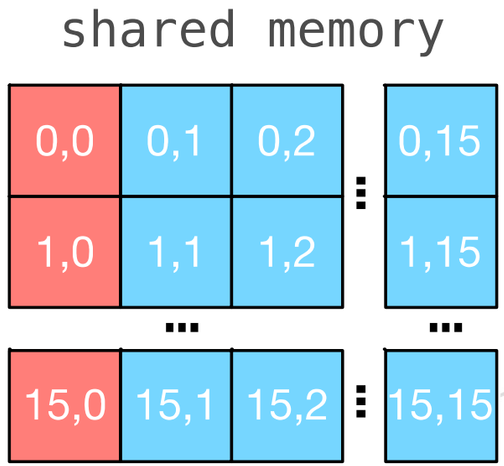
使用共享内存的CUDA矩阵转置

- 共享内存访问：存储体冲突（memory bank conflicts）
  - 从全局内存拷贝至共享内存过程中无冲突
  - 从共享内存拷贝至全局内存有冲突
    - 16-way conflicts：所有线程只对两个存储体进行操作

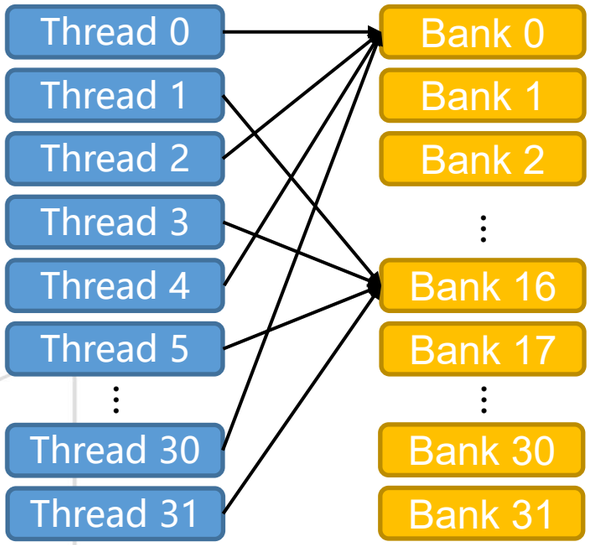




全局内存加载到共享内存
(BDIM=16)



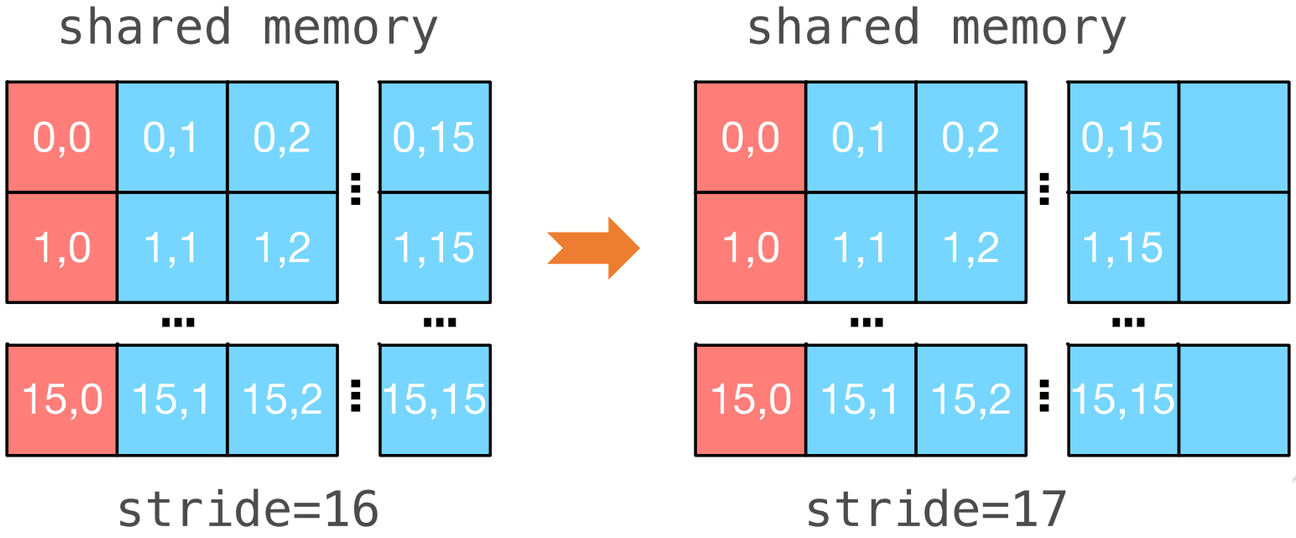
共享内存加载到全局内存
(BDIM=16)



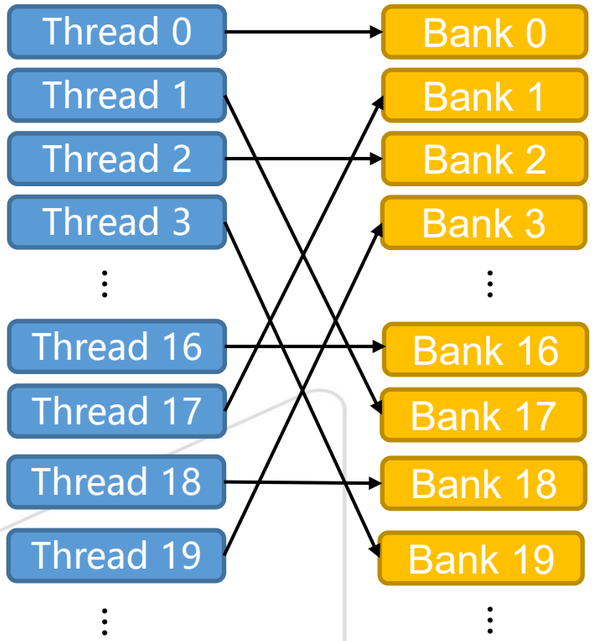
矩阵转置

使用共享内存的CUDA矩阵转置

- 共享内存访问：存储体冲突（memory bank conflicts）
  - 解决从共享内存拷贝至全局内存的存储体冲突
    - 给共享内存分配一列空白数据
    - Stride=17：无存储体冲突！



共享内存加载到全局内存
(BDIM=16)



Questions?

