

中山大學
SUN YAT-SEN UNIVERSITY



国家超级计算广州中心
NATIONAL SUPERCOMPUTER CENTER IN GUANGZHOU

并行程序设计与算法（实验）

11-CUDA图像卷积

吴迪、刘学正

中山大学 计算机学院

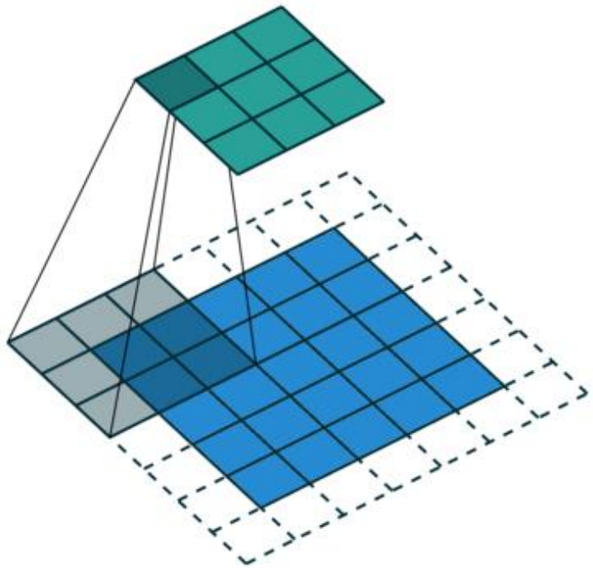
实验概要

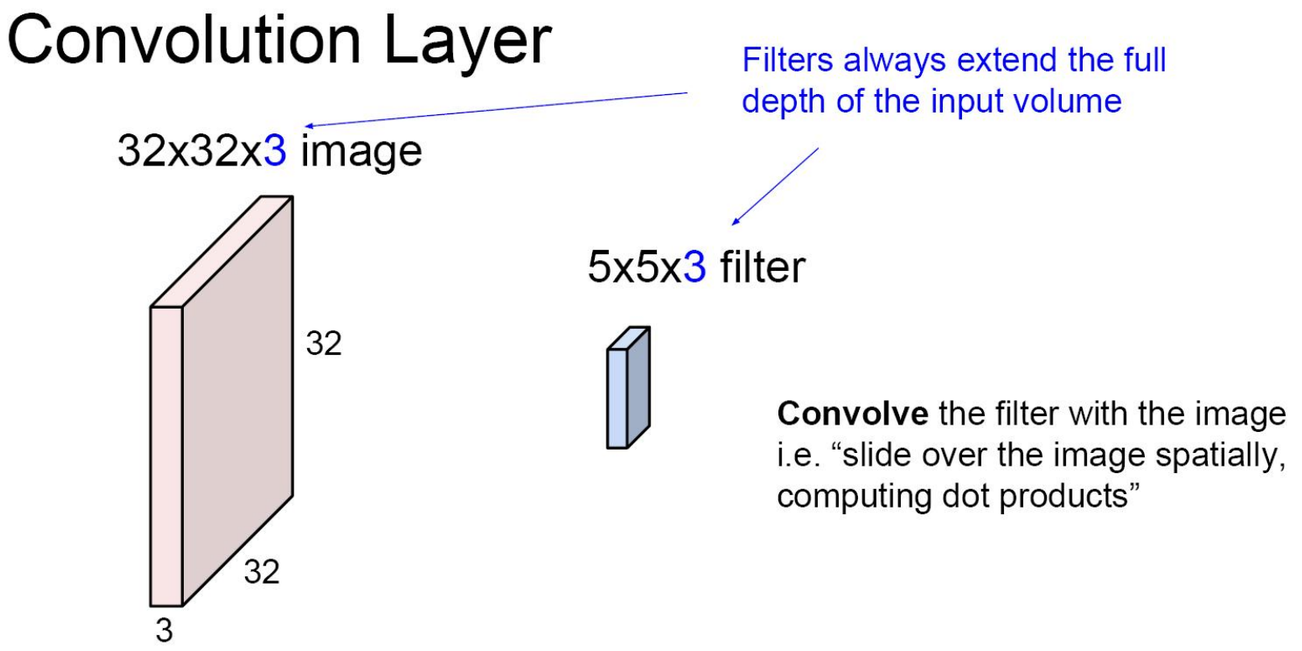
- 实验内容
  - CUDA 直接卷积（滑窗法）实现
  - im2col + GEMM 卷积优化
  - cuDNN 卷积性能对比

- 实验目的
  - 掌握 GPU 加速的卷积实现方法
  - 对比不同卷积实现的性能

直接卷积

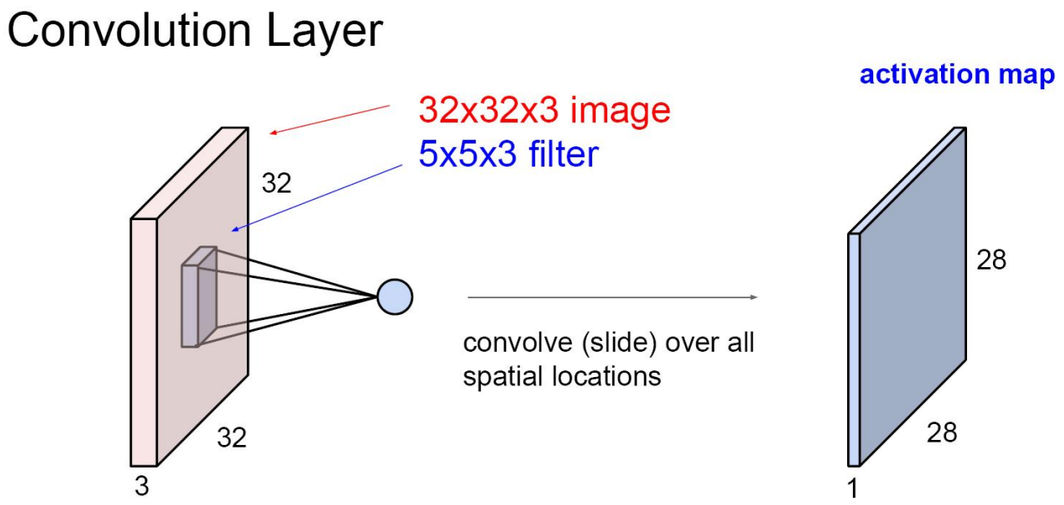
- 滑窗法
  - 卷积运算对窗口内图像像素值求加权和
  - 卷积核指明了每个像素值的权重
  - 当图像有多个通道时，需要对多个通道进行卷积

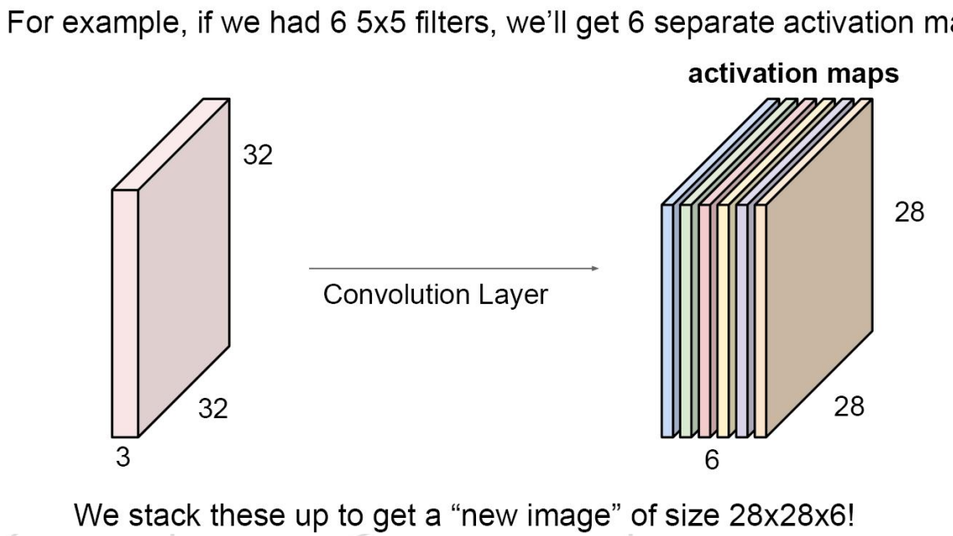




直接卷积

- 滑窗法
  - 卷积运算对窗口内图像像素值求加权和
  - 有多个滤波器时，每个滤波器都将产生一张图像作为输出

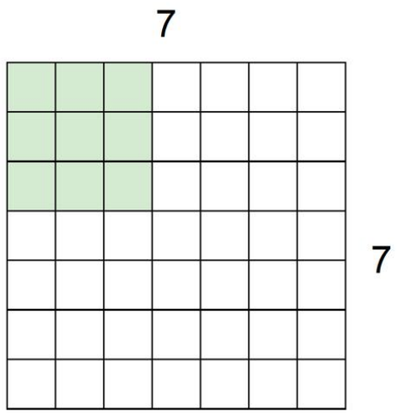




直接卷积

- 滑窗法
  - 卷积运算对窗口内图像像素值求加权和
  - 卷积核移动步长（stride）与填充（padding）

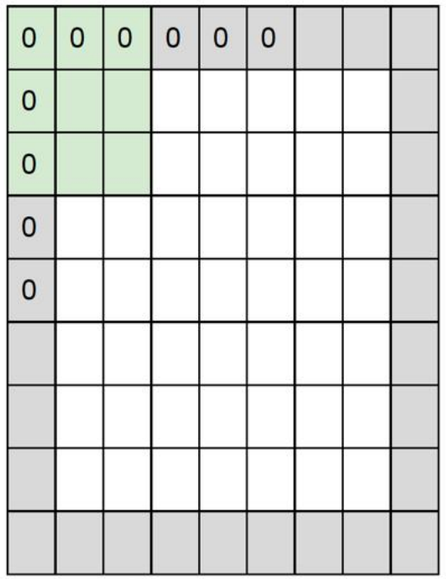
A closer look at spatial dimensions:



7x7 input (spatially)
assume 3x3 filter
applied **with stride 3?**

doesn't fit!
cannot apply 3x3 filter on 7x7 input with stride 3.

In practice: Common to zero pad the border

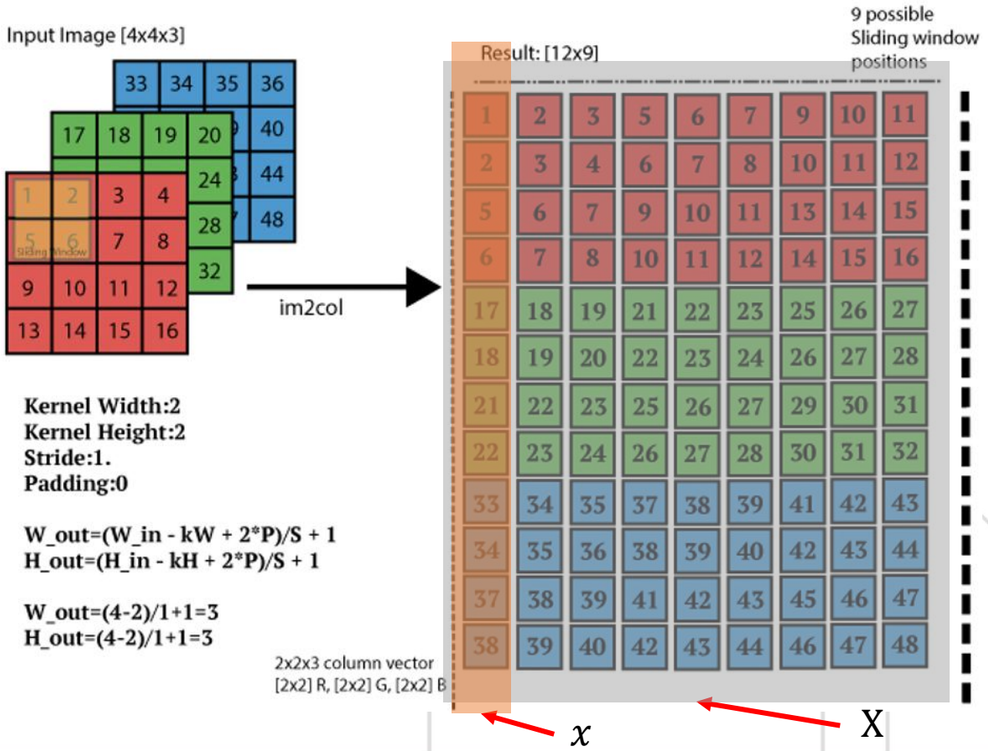


e.g. input 7x7
3x3 filter, applied with **stride 1**
pad with 1 pixel border => what is the output?

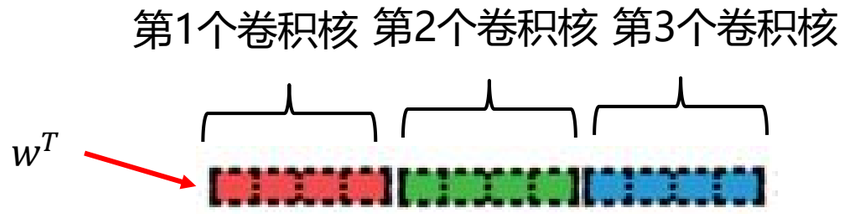
7x7 output!
in general, common to see CONV layers with stride 1, filters of size FxF, and zero-padding with (F-1)/2. (will preserve size spatially)
e.g. F = 3 => zero pad with 1
F = 5 => zero pad with 2
F = 7 => zero pad with 3

Im2col 卷积

- im2col方法
  - 每个滑动窗口中多个通道的值拼接成一个列向量 (x)
  - 将所有滑动窗口对应的列向量依次置于同一个矩阵中 (X)
  - 将所有通道的卷积核拼接成一个行向量 (w^T)



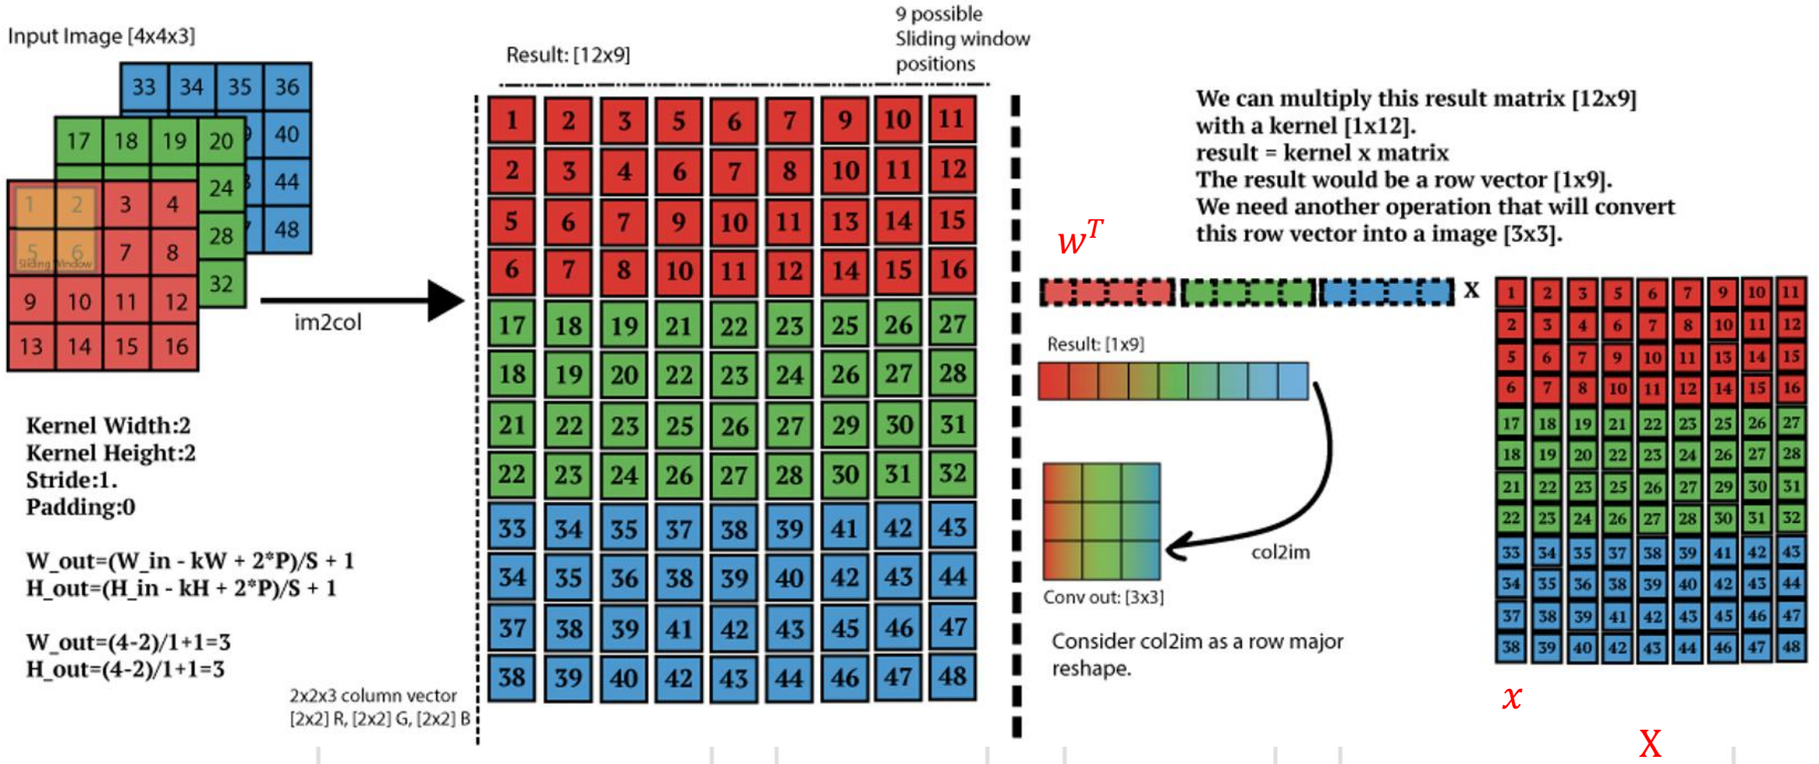




w^T：滤波器（行向量）
x：滑动窗口（列向量）
X：滑动窗口集合（矩阵）

Im2col 卷积

- im2col方法
  - 使用向量点积 $w^T \cdot x$ 实现一个滑动窗口下所有通道的卷积运算
  - 使用矩阵乘法 $w^T \cdot \mathrm{X}$ 完成所有卷积操作



实验内容

- 要求
  - 使用滑窗法、im2col方法实现CUDA并行图像卷积
  - 分析不同因素性能的影响
    - 线程块大小、图像大小：如何提高占用率?
    - 访存方式：何时使用何种存储?
    - 数据/任务划分方式：按行，列，数据块划分等
  - 使用cuDNN提供的卷积操作进行对比实验，分析自身实现的性能

Questions?

